

NOME DO DOCUMENTO

Redes_Neuronais (1).pdf

NÚMERO DE PALAVRAS

3651 Words

NÚMERO DE CARACTERES

20177 Characters

NÚMERO DE PÁGINAS

9 Pages

TAMANHO DO ARQUIVO

1.3MB

DATA DE ENVIO

Jan 15, 2024 6:38 PM GMT

DATA DO RELATÓRIO

Jan 15, 2024 6:39 PM GMT**● 10% geral de similaridade**

O total combinado de todas as correspondências, incluindo fontes sobrepostas, para cada banco de dados

- 9% Banco de dados da Internet
- Banco de dados do Crossref
- 9% Banco de dados de trabalhos enviados
- 6% Banco de dados de publicações
- Banco de dados de conteúdo publicado no Crossref

Redes Neurais

DIOGO M. RISCADO, Universidade da Beira Interior, Portugal

MANUEL MOURA, Universidade da Beira Interior, Portugal

RAFAEL MASCARENHAS, Universidade da Beira Interior, Portugal

Justificada pelo nome, a expressão *Neural Networks* serve como base para o paralelismo entre o processo de aprendizagem do ser humano e da "máquina": se considerarmos a rede sináptica do humano, torna-se mais fácil de compreender o método utilizado na computação moderna. Através de pesquisa e união de informação, tratamos neste trabalho as noções essenciais de Redes Neurais.

Additional Key Words and Phrases: Rede, Artificial, Neuronal, Nódulo, *Output*, *Input*, Inteligência

CONTENTS

Abstract	1
Contents	1
1 Introdução	1
2 O Paralelismo Biológico	2
2.1 Contextualização Histórica	3
3 A Atualidade	4
3.1 <i>Convolutional Neural Networks</i>	4
3.2 <i>Recurrent Neural Networks</i>	5
4 Outros Tipos de Redes Neurais	7
5 Considerações Éticas e Utilização	8
6 Conclusão	9
References	9

1 INTRODUÇÃO

A evolução tecnológica emergente trouxe à ribalta um termo e um processo de aprendizagem existentes no mundo da Inteligência Artificial desde 1944, denominado de *Neural Networks* ou, em português, Redes Neurais.

Para além de se tratar de um dos conceitos basilares de *Deep Learning* (uma Rede com mais de três camadas pode ser considerada um algoritmo de *Deep Learning*), o próprio nome permite-nos inferir o seu funcionamento, olhando para os processos biológicos associados aos neurónios e sinapses, ambos de importância gritante para o funcionamento regular do ser humano.

Authors' addresses: Diogo M. Riscado, Universidade da Beira Interior, Covilhã, Portugal, diogo.riscado@ubi.pt; Manuel Moura, Universidade da Beira Interior, Covilhã, Portugal, manuel.moura@ubi.pt; Rafael Mascarenhas, Universidade da Beira Interior, Covilhã, Portugal, rafael.mascarenhas@ubi.pt.

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than ACM must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.

© 2023 Association for Computing Machinery.

Manuscript submitted to ACM

Manuscript submitted to ACM

Começemos, então, por definir estes processos fazendo, de seguida, um desenvolvimento mais pormenorizado do conceito associado à área da tecnologia.

2 O PARALELISMO BIOLÓGICO

Começando pela base humana de uma rede neuronal, podemos considerar o seguinte exemplo: imagine-se uma criança a quem lhe foi dada uma bola de ténis. Foi-lhe pedido que atire a bola ao chão e que ela retorne à sua mão, não sem antes a "tabelar" com a parede.

Sabemos que as bases existentes para que esta criança consiga cumprir este desafio continuamente são os seus neurónios e nervos, que permitirão a locomoção dos membros superiores para atirar a bola, mas também a análise ocular do espaço disponível e a imaginação da trajetória da bola. Talvez ao início terá algumas dificuldades em agarrar a bola depois do lançamento, ou até na colocação no sítio certo para que esta ressalte num local propício.

Em pouco tempo, a criança terá alguma facilidade em fazer o lançamento, agarrar a bola e até mesmo alterar a forma de lançamento. Se considerarmos o *input* a bola e o desafio colocado, então o *output* será a facilidade com que a criança adquiriu este conhecimento, mas também com que facilidade o aprimorou, inclusive criando variantes.

Analogamente, uma rede neuronal artificial terá a necessidade de inserção de uma informação base de modo a atingir um objetivo final. As seguintes camadas das redes neuronais irão receber a informação processada da camada anterior, até que se chegue à última denominada de *output*, na qual é apresentada a informação final pedida, depois de analisada pelo computador. Note-se que, tal como o ser humano, a repetição e diversificação da amostra colocada como *input* poderão aumentar a eficiência, precisão e velocidade de processamento da rede criada. Tenha-se como exemplo a seguinte rede que, embora simples, serve como suporte visual.




Fig. 1. Rede Neuronal representada em diagrama, [4], https://www.ibm.com/content/dam/connectedassets-adobe-cms/worldwide-content/cdp/cf/ul/g/3a/b8/ICLH_Diagram_Batch_01_03-DeepNeuralNetwork.png.

Como é observável na figura *supra* indicada, a rede em questão tem uma camada inicial composta por cinco nós (ou nódulos), três camadas ocultas, comumente referidas como intermédias, que farão o processamento da informação que serve como alimento ao *input*, mas poderão também permitir atingir um *output*, justamente por interpretarem a informação e, inevitavelmente, facilitarem a chegada ao resultado pretendido.

2.1 Contextualização Histórica

Talvez nos seja desconhecido o funcionamento aproximado ou até a estrutura real de um neurónio humano. Entenda-se, este tipo de células é complexa no seu funcionamento, mas efetivamente simples a nível anatómico. De uma forma lata, podemos considerar que esta é composta por um núcleo, por dendrites- responsáveis por obterem o sinal orientado por neurónios associados anteriormente- pelo axónio, que permitirá a continuidade do impulso elétrico e ao estímulo e, por fim, as ramificações terminais, que irão "passar a mensagem" para os seguintes neurónios. Ainda que explicado "por alto", foi esta a base para, em 1943, WARREN MCCULLOCH e WALTER PITTS desenvolverem o primeiro modelo de uma rede neuronal.




Fig. 2. Representação de um neurónio humano.




Fig. 3. Representação da Rede Neuronal Artificial de MCCULLOCH e PITTS ([2]).

Este modelo encontra-se dividido em duas partições: a parte g , a branca, onde estará o *input*, e a região a cinzento, que está encarregue de tomar uma decisão. Faça-se notar que a decisão e os dados introduzidos inicialmente estão compreendidos entre apenas dois valores: um e zero. Para além disso, estas variáveis são, de uma certa forma *booleanas*. Imaginemos esta situação: um indivíduo está na dúvida entre comprar ou não um gelado. A sua decisão final (ou seja, a resposta da ponderação f) será "vou comprar um gelado" ou "não vou comprar um gelado", enquanto as ponderações de g seriam, por exemplo, a existência de um sabor mais agradável ao paladar do indivíduo. De uma forma geral, esta organização neuronal é extremamente semelhante ao *Perceptron*, uma rede que tem apenas uma camada capaz de receber *inputs*, aplicar *weights* e, finalmente, gerar um *output*. É também importante justificar a noção de *weight*: as ligações entre nós/nódulos, sem exceção, têm a sua magnitude. É esta magnitude, esta "força", que permitirá uma previsão mais exata do resultado final da rede neuronal. Olhando para a Figura 1 novamente, a cada um dos elos de ligação entre camadas corresponde um valor (o *weight*) que pode ser manipulado para melhorar a especificidade da rede na função para a qual foi criada.

É certo que este sistema nos parece rudimentar, até por não ter aquilo que denominaríamos como camadas ocultas. Saltemos, então, para as aplicações modernas e para a evolução deste sistema de aprendizagem.

3 A ATUALIDADE

Iremos desenvolver diferentes características de camadas dentro de modelos de *Deep Learning* neste trabalho. Porém, achámos pertinente destacar as seguintes categorias das outras, não só por serem trabalhadas em larga escala hoje em dia, mas também para que possamos compreender quais as funcionalidades possíveis dentro destes modelos.

14.1 Convolutional Neural Networks

Uma *Convolutional Neural Network* (CNN) trata-se de uma arquitetura específica utilizada maioritariamente na deteção de padrões e símbolos em imagens ([3] e [9]). Este tipo de rede permite poupar poder computacional nas diferentes pesquisas efetuadas, justamente porque inibe a necessidade de Redes Neurais extremamente complexas sem especialidade nesta área de pesquisa. Posto de outra forma, a preparação extra de uma CNN permite que tenha sido criada para que consiga trabalhar melhor certos *inputs*. Tenhamos como base esta simplificação:

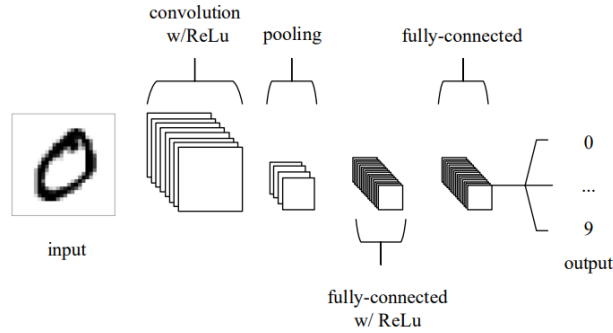


Fig. 4. Uma *Convolutional Neural Network* com cinco camadas (<https://arxiv.org/pdf/1511.08458.pdf>).

Façamos agora uma desmistificação da figura: como referimos anteriormente, é apresentada uma imagem à estrutura neuronal. Imediatamente após o *input*, surge um termo específico das CNN, uma *Convolution*. Esta operação é, no fundo, uma conversão dos píxeis da imagem numa área definida previamente em valores, de forma a criar vetores e permitir uma amostra menor numericamente, mas com um maior número de subdivisões (escolhemos não entrar em pormenor na parte matemática do tópico ainda que, obviamente, haja um trabalho numérico gritante por detrás do procedimento que descrevemos). Este procedimento permite ¹⁵ extração de características da imagem, através de filtros denominados de *Kernels*. Estes filtros são, nada mais nada menos, que matrizes que irão transpor a informação numérica para ser analisada por uma camada seguinte.

Segue-se uma camada de *Pooling*, que fará uma redução do mapa de características da informação fornecida, de modo a diminuir a carga computacional e a evitar um fenómeno chamado de *Overfitting* - quando a Rede Neuronal se adapta demasiado às flutuações específicas do *input* e, portanto, adquire imensa informação desnecessária para outras imagens fornecidas ou até mesmo para o objetivo inicial. Existem dois tipos de *pooling*: *Max Pooling* (escolha do representante com maior valor absoluto de uma das divisões) ou *Average Pooling* (efetuar a média dos valores presentes numa das divisões).

Surgem agora Camadas Densas, ou *Fully Connected Layers*, camadas responsáveis por categorizarem a informação obtida anteriormente e permitirem, finalmente, um *output*.

Resumidamente, a Rede Neuronal Convolutiva descrita acima irá dividir a imagem dada, classificá-la de diferentes formas e, por fim, reconhecer qual a informação adquirida. Neste caso específico, o *input* trata-se de uma imagem do algarismo zero, e assim será identificado pela rede.

3.2 Recurrent Neural Networks

Uma outra área na qual a Inteligência Artificial tem tido uma evolução exponencial é no reconhecimento de texto, na qual as Redes Neurais Recorrentes (RNN) ganham força. À luz do trabalho desenvolvido por ROBIN M. SCHMIDT, a forma com que se diferenciam das CNN permitem uma melhor adaptabilidade à área de *Text Recognition*, ao invés de *Image Recognition* ([5], [13]).

Desde já, consideramos a primeira disparidade quando comparamos com uma típica *Feed-Forward Neural Network*: as RNN permitem que determinadas camadas intermédias consigam reter e analisar dados ciclicamente. Posto de outra forma, a camada que recebe dados conseguirá enviá-los não só para uma seguinte camada, mas também aprender com a informação que iria enviar (ou seja, retorná-la ao *input*).

As RNN são também distinguíveis pela adaptabilidade e capacidade de contextualização. Em situações de Processamento de Linguagem Natural, este tipo de rede permite a previsão das palavras seguintes numa frase, devido à sua (permita-se a analogia) "memória". Grande parte dos motores de busca ou assistentes virtuais se baseia neste tipo de funcionamento - veja-se a Siri e o Google Tradutor. Podemos exemplificar desta forma:




Fig. 5. Uma *Recurrent Neural Network* de forma simplificada e o seu funcionamento explicado ([10], [8]) (<https://arxiv.org/pdf/1912.05911.pdf>).

Como foi referido anteriormente, a redução da quantidade de camadas ocultas não invalida o processamento de dados, uma vez que a camada intermédia deste exemplo - a camada A - terá por si só diferentes *weights* associados, o que permitirá a análise de dados de formas diferentes. Esta explicação é um dos fatores para podermos compreender o motivo pelo qual a Siri, a Bixby, a Alexa e a Assistente de voz da Google conseguem manter uma conversa e fazer diferentes tarefas: a capacidade de interpretar o que lhes é dito devido à capacidade de aprendizagem e retenção de informação prévia.

O uso de RNNs enfrentou problemas na capacidade de processamento devido aos chamados conflitos de gradiente. O gradiente é, de uma forma sucinta, uma quantificação de quanto varia o *output* em função de variações efetuadas no *input*. Os dois principais problemas de gradiente denominam-se de *Exploding Gradient* e *Vanishing Gradient*. O primeiro caso ocorre quando os *weights* atribuídos pelo próprio algoritmo são exacerbados sem razão aparente. Neste caso, a resolução passa por fórmulas matemáticas que permitem compactar os dados de maneira mais eficiente. No segundo caso, os valores em questão iriam tender para zero.

Esta distinção é importantíssima para podermos introduzir a ¹² *Long Short-Term Memory Networks*, doravante LSTM.

3.2.1 Long Short-Term Memory Networks. Em 1997, numa tentativa de solucionar o problema do *Vanishing Gradient*, JOSEF HOCHREITER e JÜRGEN SCHMIDHUBER criam as LSTM. Neste tipo de rede, é adicionada à arquitetura normal de uma RNN uma "célula LSTM" à camada intermédia (olhando para a Figura 5, esta célula seria implementada na camada A). Podemos decompô-la da seguinte forma:

Partição	Função
<i>Forget Gate</i>	Componente que dará a possibilidade à rede de manter ou descartar determinadas informações previamente adquiridas, <i>i.e.</i> , permite selecionar as informações mais pertinentes.
<i>Input Gate</i>	<i>Gate</i> que quantificará a importância da informação obtida nos <i>inputs</i> anteriores e enviá-los-á para o seguinte procedimento.
<i>Output Gate</i>	Responsável por determinar o valor da camada oculta seguinte, uma vez que também contém informações sobre os <i>inputs</i> anteriores.

Deste modo, torna-se mais clara a necessidade de implementar as LSTM nos modelos de aprendizagem modernos. O problema do gradiente torna-se obsoleto, as dependências a longo prazo de informação estão seguras e, apesar do processo de treino ser mais duradouro e complexo, estas são mais competentes a lidar com informações sequenciais de grande escala, como os assistentes de voz referidos acima ([12], [14]).

3.2.2 Gated Recurrent Units (GRU). De uma forma muito sucinta, as GRU descomplexificaram as LSTM, mantendo o seu grau de eficiência e sucesso. Neste caso, a rede em questão apresenta apenas dois gates: o *Update Gate* e o *Reset Gate*. A primeira fica responsável pela interpretação da informação prévia (de modo a compreender o que é útil ou não)

e por classificar as informações novas como relevantes ou supérfluas. De forma análoga, efetuará as funções dos *Forget* e *Input Gates*, respetivamente. Quanto ao *Reset Gate*, este irá decidir, numericamente, quanta informação anteriormente adquirida pode ser desprezada ([11]).

3.2.3 LSTMs Vs GRUs. Ao compararmos as duas arquiteturas, vemos que ambas terão funcionalidades idênticas. Por esse motivo, não surge uma em detrimento da outra, mas sim alternativas de eficiência. As GRUs, normalmente, ocupam menos tempo de treino que as LSTMs, o que não implica que sejam mais descompensadas ou propícias a erro. No fundo, os investigadores devem compreender primeiro qual das estruturas se aplica melhor à função que desejam.

4 OUTROS TIPOS DE REDES NEURONAIS

Apesar de destacarmos estes dois tipos de Redes na secção anterior, é fulcral distinguirmos também outras classificações possíveis, tais como:

- **Redes Generativas Adversariais (GAN):** Expliquemos as GAN (*Generative Adversarial Networks*) através de um jogo de soma zero. Tenha-se um Gerador, capaz de criar imagens fictícias e de as dirigir a um Discriminador, que tentará compreender se o objeto que lhe foi dado é criado pelo Gerador ou faz parte do Domínio inserido humanamente na Rede Neuronal. Se o Discriminador compreender que a imagem é falsa, o "jogo" é ganho pelo mesmo e o primeiro altera-se de maneira a tentar enganar o vencedor anterior. Se, por outro lado, o Gerador "ganhar", então o perdedor terá de se "auto-atualizar" de forma a compreender quais os elementos fornecidos que distinguem a criação artificial do *input* humano.

Desta forma, consideramos que o Gerador está pronto quando conseguir enganar sucessivamente o Discriminador. É fácil de compreender de que forma as GAN podem ser utilizadas paralelamente com as CNN: o seu uso em análise de imagens e padrões permite uma combinação perfeita entre ambas as arquiteturas. É também fácil de exemplificar a utilidade das GAN: Imagine-se que o Domínio inserido pelo ser humano consistia em imagens



Fig. 6. Um rosto criado por um *software* inteiramente gratuito. (<https://www.fotor.com/images/create>).

de pessoas do sexo feminino (ou com características aparentes). A Figura 6 seria a criação do Gerador (neste caso, com a *Prompt* "senhora ruiva com olhos pretos, sem sardas, nariz pequeno, lábio superior grande, linha do maxilar fina") e seria enviada para o Discriminador, para este a analisar e a considerar real ou criação artificial.

A evolução de ambos os componentes deste tipo de Rede Neuronal fará com que os modelos criados sejam cada vez mais realistas, mas também criará sistemas extremamente capazes de detetar imagens reais ([1]).

- Autoencoders: Um tipo de Rede Neuronal extremamente versátil, os *Autoencoders* são capazes de aprender novas tarefas, reduzir a dimensão de trabalho de um ficheiro, retirar o ruído dos dados (*Data Denoising*), comprimir imagens e detetar anomalias nos processos de informação inerentes à sua utilização. Na sua essência, estas redes têm uma camada *Encoder*, uma outra camada *Decoder* e, por norma, considera-se o espaço do meio um *Bottleneck*. O primeiro tem como função reduzir e comprimir os dados propostos no *input* o máximo possível, de forma a codificá-lo e interpretá-lo numa outra Rede Neuronal e/ou testar a resposta final. De certa forma, quando consideramos que os dados iniciais já foram reduzidos para manter apenas as características mais importantes, consideramos que atingimos o *Bottleneck* (em português, o "gargalo") da rede. Como o próprio nome indica, é neste momento que a informação está o mais comprimida possível. A partir daqui, o *Decoder* entra em ação, tentando reconstruir o *input* retirando as informações supérfluas e permitindo que o *output* não ocupe tanto armazenamento quanto o *input* inicial.




Fig. 7. Um exemplo de um *Autoencoder*. ¹¹ <https://www.analyticsvidhya.com/blog/2021/06/autoencoders-a-gentle-introduction/#h-what-are-autoencoders>.

Como a figura indica, o *Bottleneck* da rede pode ser reaproveitado numa outra estrutura Neuronal, com uma arquitetura completamente diferente. Por exemplo, uma GAN pode aproveitar estes dados para treinar o seu Discriminador. Através deste exemplo conseguimos compreender que os diferentes termos de Inteligência Artificial devem ser trabalhados minuciosamente, até do ponto de vista do armazenamento (uma vez que a capacidade de memória não é ilimitada) ([6]).

5 CONSIDERAÇÕES ÉTICAS E UTILIZAÇÃO

Apesar de ser uma área em crescimento frenético e extremamente promissora para o futuro, é imperativo criarmos inferências éticas sobre o que virá daqui para a frente. Achámos pertinente separar "o trigo do joio", deixando este comentário: compete ao ser humano competente na área (seja programador, cientista de dados ou engenheiro) esclarecer as dúvidas e os receios que possam surgir em relação à área. Citemos FRANKLIN D. ROOSEVELT no que toca ao medo: ⁶ *the only thing we need to fear is fear itself* ("a única coisa que devemos temer é o próprio medo"). Como qualquer outra área até então desconhecida ao público, é natural que a perceção existente na sociedade seja uma de pouca recetividade ou de alguma necessidade de ocultar o desenvolvimento generalizado da dita área. Porém, compete aos profissionais competentes assegurarem à restante sociedade de que apenas através do estudo intensivo e da pesquisa (disponível ao público, entenda-se) é possível normalizar o conhecimento e progredir tecnologicamente.

Não podemos, porém, ser totalmente ingênuos e acreditar apenas na "boa-fé" dos especialistas e, embora o trabalho trate especificamente as Redes Neurais Artificiais, não podemos (nem devemos) menosprezar as etiquetas éticas a serem definidas para os trabalhadores vindouros.

Temas como a proteção de dados e a forma como os mesmos são obtidos não podem ser ofuscados ou "metidos para a gaveta". A digitalização do mundo faz com que o acesso a dados para utilização posterior seja facilitado. É, aliás, fácil conseguir criar um perfil digital apenas com dados que podemos considerar irrelevantes: a recolha da impressão digital, o uso da *Face ID*, aplicações que captem vídeo ou até áudio. Fica a cabo de cada empresa informar de forma clara e objetiva acerca das suas políticas de obtenção e utilização de dados, mas também ao utilizador informar-se e saber quando se deve opor ao termos e condições propostos.

Outro problema a considerar é denominado de *algorithmic bias* - trata-se de uma previsão incorreta de um *output*, normalmente colocando um grupo de pessoas ou uma determinada ideologia como digna de discriminação. A solução parece inevitável: a amostra inicial deve ser ampla, e não apontar para uma saída específica. Por outra, as atualizações a efetuar aos algoritmos devem ser constantes, de maneira a acompanhar o seu funcionamento e permitir que esta criação não se torne obsoleta ([7]).

6 CONCLUSÃO

Após a execução desta variada pesquisa, é possível compreender a importância das Redes Neurais Artificiais para os mecanismos de *Deep Learning* e para os conceitos generalizados de Inteligência Artificial. A quantidade de artigos e conteúdos digitais emergentes em relação ao tópico permitiu-nos efetuar um trabalho que consideramos claro e de rápida apreensão. Deste modo, conseguimos transmitir a importância destas arquiteturas para a modelagem artificial e a variedade de utilidades possíveis com o que já foi estabelecido. Resta-nos, agora, compreender até onde conseguiremos evoluir.

10 REFERENCES

- [1] BROWNLEE, J. A gentle introduction to generative adversarial networks (gans), Jun 2019.
- [2] HANDRA, A. L. Mcculloch-pitts neuron — mankind's first mathematical model of a biological neuron, Jul 2018.
- [3] M. What are convolutional neural networks?, 2023.
- [4] IBM. What are neural networks?, 2023.
- [5] IBM. What are recurrent neural networks?, 2023.
- [6] MICHELUCCI, U. *An Introduction to Autoencoders*. 2022.
- [7] ÜLLER, V. C. Ethics of Artificial Intelligence and Robotics. In *The Stanford Encyclopedia of Philosophy*, E. N. Zalta and U. Nodelman, Eds., Fall 2023 ed. Metaphysics Research Lab, Stanford University, 2023.
- [8] NABI, J. Recurrent neural networks (rnns) - towards data science, Jul 2019.
- [9] O'SHEA, K., AND NASH, R. An introduction to convolutional neural networks, 2015.
- [10] POUDEL, S. Recurrent neural network (rnn) architecture explained, Aug 2023.
- [11] SAXENA, S. Introduction to gated-recurrent unit (gru), Mar 2021.
- [12] SAXENA, S. Introduction to lstm (long short term memory) | deep learning, Mar 2021.
- [13] STANFORD. Cs230 recurrent neural network cheat sheet, 2023.
- [14] JI, Y., SI, X., HU, C., AND ZHANG, J. A review of recurrent neural networks: Lstm cells and network architectures. *Neural Computation* 31, 7 (Jul 2019), 1235–1270.

● 10% geral de similaridade

As principais fontes encontradas nos seguintes bancos de dados:

- 9% Banco de dados da Internet
- Banco de dados do Crossref
- 9% Banco de dados de trabalhos enviados
- 6% Banco de dados de publicações
- Banco de dados de conteúdo publicado no Crossref

PRINCIPAIS FONTES

As fontes com o maior número de correspondências no envio. Fontes sobrepostas não serão exibidas.

1	arxiv.org Internet	3%
2	University of Canterbury on 2023-10-24 Submitted works	<1%
3	trepo.tuni.fi Internet	<1%
4	Unviersidad de Granada on 2023-09-06 Submitted works	<1%
5	uri.gbv.de Internet	<1%
6	www1.folha.uol.com.br Internet	<1%
7	repositorio.ufla.br Internet	<1%
8	Imperial College of Science, Technology and Medicine on 2020-06-14 Submitted works	<1%

9	University of Wales Swansea on 2023-09-25	<1%
	Submitted works	
10	isg-konf.com	<1%
	Internet	
11	Colorado State University, Global Campus on 2023-01-30	<1%
	Submitted works	
12	University of Canberra on 2024-01-10	<1%
	Submitted works	
13	groundai.com	<1%
	Internet	
14	export.arxiv.org	<1%
	Internet	
15	repositorio.ufrn.br	<1%
	Internet	
16	repositorio.unifei.edu.br	<1%
	Internet	
17	A. P. Rauter. "Synthetic, Fungicidal Unsaturated- γ -lactones Attached to...	<1%
	Crossref	
18	Sepp Hochreiter, Jürgen Schmidhuber. "Long Short-Term Memory", Ne...	<1%
	Crossref	
19	University of Liverpool on 2023-04-28	<1%
	Submitted works	