

NOME DO DOCUMENTO

**Relatório\_sobre\_Deep\_Learning.pdf**

NÚMERO DE PALAVRAS

**3325 Words**

NÚMERO DE CARACTERES

**18652 Characters**

NÚMERO DE PÁGINAS

**10 Pages**

TAMANHO DO ARQUIVO

**888.9KB**

DATA DE ENVIO

**Jan 15, 2024 6:38 PM GMT**

DATA DO RELATÓRIO

**Jan 15, 2024 6:39 PM GMT****● 32% geral de similaridade**

O total combinado de todas as correspondências, incluindo fontes sobrepostas, para cada banco de dados

- 28% Banco de dados da Internet
- 3% Banco de dados de publicações
- Banco de dados do Crossref
- Banco de dados de conteúdo publicado no Crossref
- 10% Banco de dados de trabalhos enviados

# Relatório sobre o Deep Learning

GUILHERME CARDOSO, Faculdade Beira Interior, Portugal

DINIS AMADO, Faculdade Beira Interior, Portugal

O Deep Learning é um conjunto de tecnologias e algoritmos em rápida evolução, utilizados por investigadores e cientistas de dados para construir, treinar e testar, redes neuronais artificiais para uso em modelos preditivos, com o objetivo de probabilisticamente identificar padrões complexos em dados.

7 Additional Key Words and Phrases: Deep Learning, Inteligência Artificial (AI), Machine Learning (ML), Redes Neuronais

## ÍNDICE:

### CONTENTS

Abstract	1
Contents	1
1 Introdução ao Deep Learning	2
1.1 O que é o Deep Learning?	2
1.2 Diferenças entre o Deep Learning e o Machine Learning	3
2 Redes Neuronais	4
2.1 Arquitetura e Componentes	4
2.2 Principais Tipos de Redes Neuronais	6
2.3 Treino de Modelos Baseados em Redes Neuronais	7
3 Aplicações do Deep Learning	7
4 Desafios na Implementação do Deep Learning	9
5 Soluções na Implementação do Deep Learning	9
6 Conclusão	10
References	10

Authors' addresses: Guilherme Cardoso, Faculdade Beira Interior, Covilhã, Portugal; Dinis Amado, Faculdade Beira Interior, Covilhã, Portugal.

# 1 INTRODUÇÃO AO DEEP LEARNING

Este documento vai abranger os fundamentos do Deep Learning, o seu futuro e a sua função no desenvolvimento de Inteligência Artificial. Através deste trabalho pretendemos dar a conhecer, mostrar e explicar o que é o Deep Learning, quais as diferenças entre o Deep Learning e o Machine Learning, principais características e as suas aplicações.

Esta apresentação destaca os elementos fundamentais do Deep Learning, uma tecnologia revolucionária que utiliza redes neuronais profundas para aprender padrões complexos. Discute os seus componentes, tais como os tipos de redes neuronais, funções de ativação, retropropagação, CNNs e RNNs. Aborda desafios comuns como o overfitting e a rotulação dos dados, mitigando os mesmos com soluções práticas. A apresentação também destaca o impacto positivo do Deep Learning em vários domínios, como o reconhecimento de imagens e o processamento de linguagem natural.

## 1.1 1 que é o Deep Learning?

O Deep Learning é um subconjunto de machine learning, constituído essencialmente por camadas de redes neuronais. Estas redes simulam o comportamento do cérebro humano, simulando a sua capacidade de “aprender” sobretudo quando são utilizadas grandes quantidades de dados.

Esta metodologia é aplicada em situações onde o problema é tão complexo ou o volume de dados é tão grande que abordagens convencionais não conseguem resolver. Desta forma, fornecemos estes dados para um sistema computacional de Deep Learning que procura um modelo que represente ou que melhor se aproxime do objetivo a ser alcançado.

1 Embora uma rede neural de camada única ainda possa fazer previsões aproximadas, camadas ocultas adicionais podem ajudar a otimizar e melhorar a precisão 6 desempenhar tarefas semelhantes às dos humanos, tais como, reconhecimento de voz falada, identificação de imagem, e a fazer previsões. Melhora a capacidade de classificar, reconhecer, detetar e descrever através de dados. O atual interesse em Deep Learning deve-se, em parte, ao entusiasmo existente em torno da inteligência artificial (IA). [8] [7] [4]




Fig. 1. Deep Learning

1.2 Diferenças entre o Deep Learning e Machine Learning

Se o Deep Learning é um subconjunto do Machine Learning, em que é que são diferentes?

O Deep Learning difere do Machine Learning clássico no tipo de dados e nos métodos de aprendizagem que utiliza. Algoritmos de Machine Learning usam dados estruturados e rotulados para fazer previsões, o que significa que recursos específicos são definidos com base nos dados de entrada do modelo e organizados em tabelas. Isso não significa necessariamente que não use dados não estruturados, significa apenas que, se existirem, geralmente passam por algum pré-processamento para organizá-los em um formato estruturado.

O Deep Learning elimina parte do pré-processamento de dados normalmente envolvido no Machine Learning. Esses algoritmos podem ingerir e processar dados não estruturados, como texto e imagens, e extrair recursos automaticamente, eliminando assim alguma dependência de especialistas humanos.

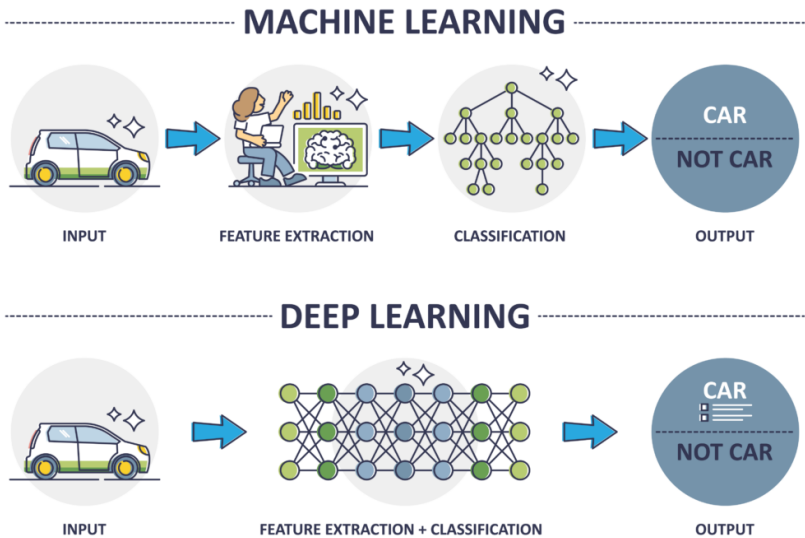


Fig. 2. Diferença entre Machine learning e Deep Learning.

## 2 REDES NEURONAIS

22 As Redes Neurais, também conhecidas como Redes Neurais artificiais (RNA) ou Redes Neurais simuladas (RNS), são um subconjunto de algoritmos de aprendizagem automática inspirados no cérebro humano. São constituídas por pares de neurónios (Nodes) com uma entrada, uma saída e um limite de segurança (resultado da Activation Function). Cada neurónio liga-se a outro com um peso (weight) associado. Se o valor resultante da Activation function estiver acima do limite especificado, o neurónio não será ativado, e não enviará os dados para a rede seguinte. [2] [5] [1]

### 2.1 Arquitetura e Componentes

O Deep Learning funciona com base em redes neurais profundas, que são modelos matemáticos compostos por várias unidades interligadas inspiradas na estrutura e função do cérebro humano. Funciona através de várias camadas principais: camada de entrada (Input Layer), camadas ocultas (Hidden Layers), camadas de saída (Output Layers) e função de ativação (Activation Function).




Fig. 3. Arquitetura de camadas de um modelo de Deep Learning.

- **Input Layer** - A camada de entrada recebe os dados na forma de imagem, texto, áudio ou qualquer tipo de informação. Cada neurónio na camada de entrada corresponde a uma característica específica dos dados.
- **Hidden Layers** - As camadas ocultas são onde a maioria do processamento ocorre e cada neurónio nessas camadas está conectado a neurónios nas camadas anteriores e posteriores. Durante o treino, os pesos das conexões entre os neurónios são ajustados para melhorar a representação dos dados.
- **Output Layer** - A camada de saída produz os resultados finais da rede. A configuração dessa camada depende do tipo de tarefa que a rede está a realizar, podendo ser uma única saída para

tarefas de regressão (valor numérico específico), ou várias saídas para tarefas de classificação (encontrar uma classe dentro de um conjunto de soluções limitadas pelo problema).

- **Activation Function** - Cada neurónio numa camada oculta aplica uma função de ativação aos seus inputs ponderados e isso introduz uma não linearidade nas operações da rede, permitindo que a rede aprenda relações complexas nos dados.

As funções de ativação são usadas em modelos de Deep Learning para introduzir a não linearidade na análise preditiva. Em muitos problemas, temos uma relação não linear entre as variáveis que afetam o resultado e o cenário final, target.

### Estas são algumas funções de ativação populares no Deep Learning:

1. **\*Sigmóide (Logística)\***: A função sigmóide (também conhecida como função logística) é uma das funções de ativação mais amplamente utilizadas.

Fórmula:

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (1)$$

Intervalo de Saída: (0, 1)

Mapeia qualquer entrada para um intervalo entre 0 e 1. Usada principalmente na camada de saída de modelos de classificação binária.

2. **\*Tangente Hiperbólica (tanh)\***: A função tanh é muito semelhante à função Sigmoid. A função é uma curva em forma de S comum também.

Fórmula:

$$\tanh(x) = \frac{e^{2x} - 1}{e^{2x} + 1} \quad (2)$$

Intervalo de Saída: (-1, 1)

Semelhante à sigmoide, mas com um intervalo de saída expandido, o que ajuda a mitigar o problema do desaparecimento de gradientes.

3. **\*Unidade Linear Retificada (ReLU)**

Fórmula:

$$\text{ReLU}(x) = \max(0, x) \quad (3)$$

Intervalo de Saída: [0, ∞)

Ativa para valores positivos, introduzindo não linearidades. É amplamente utilizada devido à sua simplicidade e eficácia.

#### 4. \*Leaky ReLU\*

Fórmula:  $\text{Leaky ReLU}(x) = \max(\alpha x, x)$ , onde  $\alpha$  é um pequeno valor positivo.

Intervalo de Saída:  $(-\infty, \infty)$

Uma variação do ReLU que permite um pequeno gradiente para valores negativos, ajudando a resolver o problema de neurónios mortos.

#### 5. \*Unidades lineares exponenciais (ELU)\*

Fórmula:  $\text{ELU}(x) = \begin{cases} x & \text{se } x > 0 \\ \alpha(e^x - 1) & \text{se } x \leq 0 \end{cases}$  onde  $\alpha$  é um pequeno valor positivo.

Intervalo de Saída:  $(-\infty, \infty)$

Semelhante ao Leaky ReLU, mas com uma suavização para valores negativos, tornando a ativação contínua.

Cada uma dessas funções de ativação tem suas próprias características e usos. A escolha da função de ativação depende do problema específico que estamos a tentar resolver com o modelo de Deep Learning.

## 2.2 Principais Tipos de Redes Neurais

### 9. Redes Neurais Convolucionais (CNNs):

Redes neurais convolucionais (CNN) consistem em um sistema de neurónios interconectados com a diferença de que cada neurónio possui um peso e uma tendência de aprendizagem.

Outra diferença que define esta rede é o fato de utilizar uma camada convolucional, em pelo menos uma das suas *Hidden Layers* que serve para identificar padrões específicos em problemas onde existe uma grande quantidade de dados. Normalmente estes modelos utilizam também: - 14. Camadas de pooling para reduzir a dimensionalidade das características preservando a informação mais importante. - Camadas totalmente conectadas (FCL) com o objetivo de observar o problema de forma global. - Camadas de Normalização que servem para melhorar a estabilidade do próprio modelo e acelerar o treino.

Esta RNA foi inicialmente desenvolvida por Yann LeCun's em 1998, sendo amplamente utilizada no reconhecimento facial, processamento de imagens, detecção e localização de objetos e também no reconhecimento óptico de caracteres (OCR) para digitalizar texto e tornar possível o processamento de linguagem natural em documentos analógicos e manuscritos, onde as 28. imagens são símbolos a serem transcritos. [1]

### • Redes Neurais Recorrentes(RNNs)

As redes neurais recorrentes (RNN) foram concebidas para tratar dados sequenciais, em que a ordem e a dependência temporal são fundamentais. São amplamente utilizadas em tarefas como 26. processamento de linguagem natural, o reconhecimento de voz e a 14. previsão de séries temporais. As RNNs têm vários componentes e conceitos:

- **Processamento de sequências de dados** - É o tratamento de informações que acontecem de forma sequencial tais como as palavras de uma frase ou acontecimentos ao longo do tempo, ou seja, cada processamento de um determinado dado tem memória do anterior.
- **Retropropagação no tempo** - Utiliza os mecanismos de Backward Propagation para verificar erros num contexto temporal.
- **Arquiteturas específicas** - Este tipo de redes necessita do uso de Arquiteturas específicas para controlar os contextos sequenciais passado e futuro, resolvendo o **Problema do Esquecimento** evitando perda de informação importante ao longo da rede.

Estas redes servem essencialmente para o processamento de linguagem natural, tradução automática entre idiomas, análise de sentimentos, reconhecimento de voz e de sequências de áudio.

Uma das dificuldades associadas a estas redes está na forma como se comportam no treino, as RNNs podem ser explosivas ou desaparecer, com o gradiente a crescer exponencialmente ou a diminuir drasticamente.

## 2.3 Treino de Modelos Baseados em Redes Neurais

O treino de modelos de Deep Learning envolve várias etapas e desafios.

Em primeiro lugar a preparação dos dados, o Deep Learning requer conjuntos de dados de treino substanciais e representativos para que os modelos possam aprender com sucesso a fazer previsões precisas.

Em segundo lugar a escolha da Arquitetura do Modelo, dependendo do problema podemos escolher entre várias arquiteturas de rede neural, redes neurais convolucionais (CNNs), redes neurais recorrentes (RNNs), etc.

Durante o treino ocorrem vários momentos distintos:

1. Os dados são propagados através do modelo, da entrada para a saída prevista. Este processamento é denominado de Forward Propagation ou Feedforward.
2. Após esta iteração, o erro é calculado como a diferença entre a previsão e o alvo. Para cada peso a inclinação ou derivada do erro é encontrada, a este passo chamamos de cálculo da Perda.
3. No Backward Pass ou Backpropagation, recorre-se a algoritmos, esta parte fundamental em Deep Learning calcula os gradientes da função de perda em relação aos pesos da rede, permitindo que esses pesos sejam ajustados para minimizar o erro.

O processo de forward pass, backward pass e respetiva atualização dos pesos é repetido iterativamente através, de várias épocas, ajustando a rede até à sua ótima *performance*. [6]

## 3 APLICAÇÕES DO DEEP LEARNING

As aplicações do Deep Learning já fazem parte das nossas vidas diárias, mas na maioria dos casos elas estão tão bem integradas em produtos e serviços que os utilizadores não se apercebem da complexidade do processamento de dados que ocorre em segundo plano. Alguns destes exemplos incluem os seguintes:



- **Aplicação na lei**

Os algoritmos de Deep Learning podem analisar e aprender com dados transacionais para identificar padrões perigosos que indicam possíveis atividades fraudulentas ou criminosas. Reconhecimento de voz, visão computacional e outros aplicativos de Deep Learning podem melhorar a eficiência e a eficácia da análise investigativa, extraindo padrões e evidências de gravações de som e vídeo, imagens e documentos, o que ajuda a aplicação da lei a analisar grandes quantidades de dados com mais rapidez e precisão.

- **Serviços financeiros**

Instituições financeiras usam regularmente análises preditivas para conduzir negociação algorítmica de ações, avaliar riscos de negócios para aprovações de empréstimos, detectar fraudes e ajudar a gerir carteiras de crédito e investimento para clientes.

- **Atendimento ao cliente**

Muitas organizações incorporam tecnologia de Deep Learning nos seus processos de atendimento ao cliente. Chatbots – usados em uma variedade de aplicativos, serviços e portais de atendimento ao cliente – são uma forma direta de IA. Os chatbots tradicionais usam linguagem natural e até mesmo reconhecimento visual, normalmente encontrados em call centers. No entanto, soluções de chatbot mais sofisticadas tentam determinar, por meio da aprendizagem, se há várias respostas para perguntas ambíguas. Com base nas respostas que recebe, o chatbot tenta responder a essas perguntas diretamente ou encaminhar a conversa para um humano. Assistentes virtuais como Siri da Apple, Amazon Alexa ou Google Assistant promovem o envolvimento dos utilizadores de uma forma mais personalizada utilizando capacidades de reconhecimento de voz.

- **1 Assistência médica**

O setor de assistência médica beneficiou muito dos recursos de Deep Learning desde a digitalização de registos e imagens hospitalares. Os aplicativos de reconhecimento de imagem podem oferecer suporte a especialistas em imagens médicas e radiologistas, ajudando-os a analisar e avaliar mais imagens em menos tempo. Desenvolvimento de novos medicamentos através do Deep Learning por simulação de comportamentos de compostos fármacos pela interação entre moléculas.

- **Veículos Autónomos**

Desenvolvimento de Modelos de Deep Learning que ajudam na análise de dados de contexto sensoriais em ambientes reais, auxiliando e garantindo navegação segura e autónoma na estrada, tendo como exemplo máximo desta aplicação os modelos da Tesla, e em meios aéreos os aviões têm o piloto automático (Auto-Pilot).

- **Personalização de Conteúdos**

Algoritmos de ajuda na identificação de recomendações mais personalizadas para os utilizadores de plataformas digitais como a Netflix, HBO, Youtube, Tiktok ou Amazon Prime, e disponibilização de anúncios e conteúdos específicos para cada utilizador. As redes sociais como o Facebook e o Instagram.

## 4 DESAFIOS NA IMPLEMENTAÇÃO DO DEEP LEARNING

O Deep Learning é uma área da inteligência artificial que tem sido amplamente explorada nos últimos anos. Esta abordagem revolucionária utiliza redes neurais profundas para treinar modelos capazes de aprender e tomar decisões com base em grandes volumes de dados. No entanto, mesmo com todos os avanços tecnológicos nesta área, há momentos em que o Deep Learning se depara com obstáculos desafiadores, tais como:

- **O Desafio do Overfitting**

Um dos principais desafios do Deep Learning é lidar com o chamado overfitting. Esta situação ocorre quando o modelo se torna excessivamente ajustado aos dados de treino, perdendo a capacidade de generalizar e aplicar seu conhecimento a novos dados. Esse obstáculo pode reduzir significativamente a eficácia e confiabilidade dos modelos de Deep Learning.

- **A Necessidade de Grandes Volumes de Dados**

Outro desafio enfrentado pelo Deep Learning é a necessidade de volumes massivos de dados para treino. Essa abordagem baseada em dados requer conjuntos de treino grandes e representativos para que os modelos possam aprender com sucesso e fazer previsões precisas. No entanto, nem sempre é fácil obter acesso a esses conjuntos de dados em larga escala, o que pode dificultar o progresso no campo do Deep Learning.

- **O Tempo de Treino**

Além disso, o tempo de treino dos modelos de Deep Learning também <sup>24</sup> pode ser um desafio. Devido à complexidade das redes neurais profundas e a quantidade de dados processados durante o treino, o tempo de execução pode ser bastante demorado. Isto pode limitar a aplicação prática de certos modelos em cenários com restrições de tempo ou recursos computacionais limitados.

## 5 SOLUÇÕES NA IMPLEMENTAÇÃO DO DEEP LEARNING

Felizmente, existem diversas soluções propostas para contornar os obstáculos enfrentados pelo Deep Learning.

**Regularização** - Uma das estratégias mais utilizadas para lidar com o overfitting é a regularização. Esta técnica introduz uma penalidade na função de custo do modelo, reduzindo a complexidade do mesmo e evitando ajustes excessivos aos dados de treino.

**Aumento de Dados** - Para superar a necessidade de grandes conjuntos de dados, pode-se aplicar técnicas de aumento de dados, que consistem em gerar exemplos sintéticos adicionais a partir dos dados existentes. Isso pode ajudar a aumentar a quantidade e diversidade dos dados de treino, melhorando a generalização dos modelos.

**Transfer Learning** - O Transfer Learning é uma abordagem que permite utilizar o conhecimento prévio de um modelo treinado em uma tarefa específica para auxiliar em outra tarefa relacionada. Esta técnica pode ser útil quando há escassez de dados, permitindo aproveitar modelos pré-treinados em problemas similares.

**Redução da Dimensão dos Dados** - Quando o tamanho dos dados é um obstáculo, uma solução possível é a redução da dimensão dos dados. Técnicas como a análise de componentes principais

(PCA) podem ser aplicadas para reduzir a quantidade de informações sem perder a essência e as características mais importantes dos dados.

Estas são apenas algumas das soluções possíveis ao enfrentar os obstáculos no Deep Learning. É importante lembrar que cada desafio pode exigir uma abordagem específica e a escolha da técnica correta dependerá do problema em questão.

## 6 CONCLUSÃO

O Deep Learning está em constante evolução, com várias direções futuras e tendências promissoras a serem exploradas. Algumas áreas que poderão moldar o futuro incluem modelos mais eficientes e leves, técnicas de aprendizagem automática de máquinas (AutoML), evolução da aprendizagem semi-supervisionada e não-supervisionada, o aumento na capacidade de processamento de linguagem natural, desenvolvimento de arquiteturas híbridas para efetuar multitarefas utilizando diversos tipos de redes neurais, (CNNs) (RNNs) etc., para criar um único modelo, a aprendizagem quântica de máquinas, o uso da inteligência artificial para a saúde, desenvolvimento ético e responsável destes modelos.

Estas são apenas algumas das muitas direções para as quais o domínio do Deep Learning está a avançar, à medida que se depara com novas descobertas e desafios. O Deep Learning representa uma revolução na aprendizagem automática, impulsionando a inovação e moldando uma sociedade mais conectada, avançada e justa.

## REFERENCES

- [1] 3Blue1Brown. 2016. *Qual é o que é uma Rede Neural? Deep learning*. *Qual é o que é uma Rede Neural? Deep learning, capítulo 1*. [https://www.youtube.com/watch?v=TkwXa7Cvfr8&ab\\_channel=EmergentGarden](https://www.youtube.com/watch?v=TkwXa7Cvfr8&ab_channel=EmergentGarden) Acesso a 09/12/2023.
- [2] AMAZON. 2023. *Machine Learning and AI*. *Qual é uma rede neuronal*. AMAZON. <https://aws.amazon.com/pt/what-is/neural-network/> Acesso a 07/12/2023.
- [3] IBM. 2023. *Convolutional-neural-networks*. IBM. <https://www.ibm.com/br-pt/topics/convolutional-neural-networks> Acesso a 08/12/2023.
- [4] IBM. 2023. *O que é Deep Learning*. IBM. <https://www.ibm.com/br-pt/topics/deep-learning> Acesso a 04/12/2023.
- [5] Emergent Learning. 2023. *Matching Neural Networks Learn*. [https://www.youtube.com/watch?v=TkwXa7Cvfr8&ab\\_channel=EmergentGarden](https://www.youtube.com/watch?v=TkwXa7Cvfr8&ab_channel=EmergentGarden) Acesso a 09/12/2023.
- [6] PARETO. 2023. *Deep Learning: O Que É, Como Funciona e Exemplos*. PARETO. <https://blog.pareto.io/deep-learning/> Acesso a 08/12/2023.
- [7] Samaya Madhavan Piyush Madan. 2020. *An introduction to deep learning - Deep learning and human brain*. IBM. <https://developer.ibm.com/learningpaths/get-started-with-deep-learning/an-introduction-to-deep-learning/> Acesso a 03/12/2023.
- [8] SAS. 2023. *Deep Learning*. *Qual é e porque é importante*. SAS. [https://www.sas.com/pt\\_pt/insights/analytics/deep-learning.html](https://www.sas.com/pt_pt/insights/analytics/deep-learning.html) Acesso a 03/12/2023.

## ● 32% geral de similaridade

As principais fontes encontradas nos seguintes bancos de dados:

- 28% Banco de dados da Internet
- Banco de dados do Crossref
- 10% Banco de dados de trabalhos enviados
- 3% Banco de dados de publicações
- Banco de dados de conteúdo publicado no Crossref

### PRINCIPAIS FONTES

As fontes com o maior número de correspondências no envio. Fontes sobrepostas não serão exibidas.

1	<b>ibm.com</b> Internet	10%
2	<b>blog.pareto.io</b> Internet	4%
3	<b>ateliware.com</b> Internet	4%
4	<b>blog.mackenzie.br</b> Internet	2%
5	<b>University of Massachusetts - Amherst on 2023-12-16</b> Submitted works	2%
6	<b>sas.com</b> Internet	2%
7	<b>arxiv.org</b> Internet	<1%
8	<b>repositorio.ufsm.br</b> Internet	<1%

9	Universidade Portucalense on 2024-01-03	<1%
	Submitted works	
10	pantheon.ufrj.br	<1%
	Internet	
11	University of Wales Institute, Cardiff on 2023-03-20	<1%
	Submitted works	
12	José Eduardo Aleixo, José Luís Reis, Sandrina Francisca Teixeira, Ana ...	<1%
	Crossref	
13	Universidad de León on 2024-01-12	<1%
	Submitted works	
14	Universidade Aberta on 2023-12-11	<1%
	Submitted works	
15	rua.ua.es	<1%
	Internet	
16	Istanbul Aydin University on 2024-01-12	<1%
	Submitted works	
17	pt.scribd.com	<1%
	Internet	
18	Consorcio CIXUG on 2023-06-05	<1%
	Submitted works	
19	ESPM - Escola Superior de Propaganda e Marketing on 2023-05-30	<1%
	Submitted works	
20	Faculty of Social and Human Sciences - NOVA FCSH on 2023-12-06	<1%
	Submitted works	

21	<b>IPS Instituto Politécnico de Setubal on 2023-12-29</b>	<1%
	Submitted works	
22	<b>Universidade Nova De Lisboa on 2020-11-30</b>	<1%
	Submitted works	
23	<b>blogdazanin.blogspot.com</b>	<1%
	Internet	
24	<b>lume.ufrgs.br</b>	<1%
	Internet	
25	<b>hdl.handle.net</b>	<1%
	Internet	
26	<b>moodle.ead.serpro.gov.br</b>	<1%
	Internet	
27	<b>Aalto Yliopisto on 2023-12-03</b>	<1%
	Submitted works	
28	<b>deeplearningbook.com.br</b>	<1%
	Internet	