

Objectivos:

- Familiarização com a ferramenta FLEX;
- Introdução ao reconhecimento de padrões e expressões regulares;
- Aprendizagem dos conceitos através da realização de alguns exercícios;
- Apresentar o ambiente de trabalho proposto (secção 1.6);
- Relembrar alguns comandos básicos de Linux importantes para a utilização do FLEX (secção 1.7).

1.1 Analisadores léxicos

Um analisador léxico (*scanner*) é um programa que permite ler os caracteres de um ficheiro de texto (*e.g.*, programa-fonte) e produzir uma sequência de componentes léxicos (*tokens*) que serão utilizados pelo analisador sintáctico (*parser*) e/ou identificar erros léxicos na entrada. Além de sua função básica, o analisador léxico em geral está encarregue de fazer algumas tarefas secundárias, designadamente, a eliminação de comentários, espaços em branco e “tabulações”.

Um *token* representa um conjunto de cadeias de entrada possível e por sua vez, um lexema é uma determinada cadeia de entrada associada a um *token*. Considere os exemplos apresentados na tabela 1.1.

O FLEX é uma ferramenta que permite gerar analisadores léxicos. Estes analisadores são capazes de reconhecer padrões léxicos em texto (*e.g.*, números, identificadores e palavras-chave de uma determinada linguagem de programação). O analisador é construído com base num conjunto de regras. Uma regra é constituída por um par, padrão-acção, o padrão (expressão regular) descreve o elemento a reconhecer e acção (ou conjunto de acções) define o procedimento que será realizado no caso de identificação positiva do padrão.

Tabela 1.1: *Tokens* e lexemas

Tokens	Lexemas
FOR	for
IF	if
WHILE	while
NÚMERO	1089, 142857, 0.2, 3.14159
IDENTIFICADOR	i, j, contador, nomeAluno
OP_SOMA	+
OP_MAIOR_IGUAL	>=
ABRE_PAR	(

1.2 Modo de utilização do FLEX

O ciclo de vida de um programa FLEX obedece à estrutura apresentada na figura 1.1.

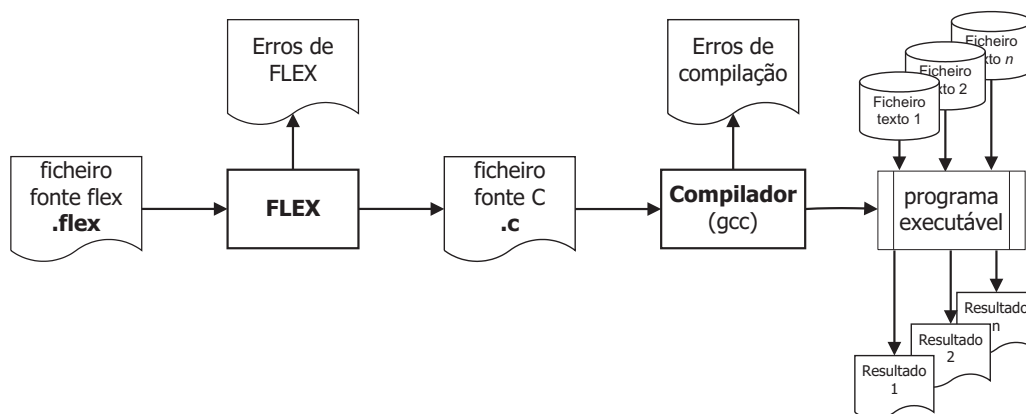


Figura 1.1: Ciclo de vida de um programa FLEX

Com base num ficheiro fonte escrito de acordo com a sintaxe do FLEX, o programa FLEX gerará um analisador léxico descrito na linguagem C. Em caso de existirem erros de codificação, o FLEX gerará uma listagem de erros. O ficheiro fonte em C terá de ser compilado para a plataforma em utilização utilizando um compilador da linguagem C adequado (neste caso o GCC). O resultado final da compilação será um programa executável capaz de identificar os padrões definidos pelo programado e levar o conjunto de acções previsto. Como entrada para o analisador gerado podem ser fornecidos ficheiros de texto ou alternativamente fornecer os dados directamente pelo *standard* de entrada.

No exemplo seguinte são apresentados os passos necessários à compilação e utilização de um programa FLEX. Considere-se a existência de um ficheiro `ficheiro.flex`

com o programa FLEX já escrito.

```
flex ficheiro.flex
gcc lex.yy.c -lfl
./a.out
```

O comando `flex` gera, por omissão, um ficheiro com o nome `lex.yy.c` que deverá ser compilado, por exemplo com o `gcc`. Na utilização do `gcc` é necessário indicar a utilização da biblioteca FLEX adicionando o parâmetro `-lfl`. Por sua vez, o compilador de C gera, por omissão, um ficheiro com o nome `a.out`. Por último, para a execução deste programa basta a evocação do seu nome na linha de comandos. Neste caso, a introdução dos dados terá de ser realizada via consola (terminando obrigatoriamente com `Ctrl+D`).

```
flex -oExemplo.c Exemplo.flex
gcc Exemplo.c -o Programa -lfl
./Programa < Dados.txt
```

Neste exemplo, o comando `flex` gera a partir do ficheiro `Exemplo.flex`, o ficheiro com o nome `Exemplo.c` que deverá ser compilado. Nesta utilização apresentada do `gcc`, é indicado o nome do executável a ser gerado, neste caso, `Programa`. Na execução do `Programa`, a introdução dos dados é realizada a partir do ficheiro `Dados.txt`.

1.3 Formato de um ficheiro FLEX

Um programa em FLEX é constituído por três secções, a saber, declarações, regras e rotinas auxiliares. A separação entre as secções é feita inserindo uma linha com o símbolo “%%”.

Considere-se o seguinte exemplo que será discutido nas secções seguintes.

```
1 %{
2     int numChars=0;
3     %}
4
5     %%
6
7     .    {
8         numChars++;
9         printf("%s",yytext);
10    }
11
12    \n    {
```

```

13         numChars++;
14         printf("\n");
15     }
16
17 %%
18
19 main()
20 {
21     yylex();
22     printf("Número_de_caracteres_%d\n", numChars);
23
24 }

```

1.3.1 Declarações

Esta secção compreende duas partes:

- **Instruções C** – nesta parte, delimitada pelos símbolos “%{” e “%}”, são colocadas as instruções da linguagem C que posteriormente serão incluídas no início do ficheiro C a gerar pelo FLEX. Os exemplos mais comuns são a inclusão de ficheiros de cabeçalhos (*headers*, *.h*), declarações de variáveis e constantes.

```

1 /* Definição da variável numChars */
2 %{
3     int numChars=0;
4 %}

```

- **Expressões regulares** – nesta parte, podem ser declaradas macros para as expressões regulares mais comuns como por exemplo algarismo ou letra do alfabeto.

```

1 /* Definição de macros */
2 ALGARISMO [0-9] /* Algarismo */
3 ALFA [a-zA-Z] /* Letra do alfabeto */

```

A utilização de macros para expressões regulares será explicada com detalhe mais adiante.

1.3.2 Regras (definição de padrões e acções)

Nesta secção são definidas as expressões regulares (padrões) e as respectivas acções que se pretendem realizar no caso da identificação positiva (*pattern matching*) do referido padrão.

No caso de um qualquer carácter excepto mudança de linha (representado por “.”) é incrementada a variável `num_chars` e impresso o referido carácter no *standard* de saída. A mudança de linha (representado por “\n”) é também contabilizada como um carácter e escrita no *standard* de saída.

As expressões regulares têm de ser **obrigatoriamente** escritas na primeira coluna do ficheiro.

```
1  .  {
2      numChars++;
3      printf ("%s", yytext );
4  }
5
6  \n  {
7      numChars++;
8      printf ("\\n");
9  }
```

Na secção 1.8 são apresentados alguns dos padrões mais relevantes utilizados pelo FLEX.

o analisador léxico gerado funciona de acordo com as seguintes regras:

- Apenas uma regra é aplicada à entrada de dados;
- A acção executada corresponde à expressão que consome o maior número de caracteres;
- Caso existam duas ou mais expressões que consumam igual número de caracteres, tem precedência a regra que aparece em primeiro no ficheiro.

Quando um padrão é reconhecido, a sequência de caracteres consumida (*token*) na identificação do padrão é guardada na variável `yytext` (do tipo `char *`). Para além disso, o comprimento da referida sequência é guardado na variável `yylen`¹ (do tipo `int`).

1.3.3 Rotinas em C de suporte

Nesta secção pode ser escrito o código C que se pretende que seja adicionado ao programa a gerar pelo FLEX. Tipicamente este código inclui o corpo do programa, designadamente, a função `main()` da linguagem C.

```
1 main()
2 {
3     yylex();
4     printf ("Número de caracteres %d\\n", numChars);
5 }
```

¹O valor desta variável poderia ser obtido através da instrução da linguagem C `strlen(yytext)`

A função `yylex()` evoca o analisador léxico gerado pelo flex que processará as expressões regulares anteriormente descritas (ver secção [1.3.2](#)).

1.4 Exemplo mais elaborado

Considere o seguinte exemplo, no qual é contabilizado a quantidade de números e de linhas existentes no ficheiro. Neste exemplo recorre-se à utilização de uma macro para a definição de algarismo.

```
1  %{
2  int qtdNumeros=0, nLinhas=0;
3  %}
4
5  ALGARISMO    [0-9]
6
7  %%
8
9  /* Se a acção for descrita numa só linha
10     as chavetas podem ser omitidas */
11
12  \n          nLinhas++;
13  {ALGARISMO}+ { printf("d_%s\n",yytext); qtdNumeros++;}
14  .
15
16  %%
17  main()
18  {
19      yylex();
20      printf("#_linhas=%d\n", nLinhas);
21      printf("#_numeros=%d\n", qtdNumeros);
22  }
```

Todos os caracteres não processados pelas duas primeiras expressões regulares são consumidos pela última à qual não corresponde nenhuma acção particular.

1.5 Propostas de exercícios

- a) Escrever um programa que permite contar o número de ocorrências de uma cadeia de caracteres;
- b) Escrever um programa que permite substituir uma cadeia de caracteres por outra;

- c) Escrever um programa que dado um ficheiro de texto, mostra:
- número de algarismos;
 - número de letras do alfabeto;
 - número de linhas de texto;
 - número de espaços ou tabulações (`\t`);
 - número de caracteres não identificados nos pontos anteriores;
- d) Escrever um programa que permite identificar números naturais;

Entrada	Saída
123 abc 12.45 s 245 xyz	123 12 45 245
xyz 2 abc 45 cc	2 45

- e) Escrever um programa que permite identificar números inteiros (com ou sem sinal);
- f) Escrever um programa que permite identificar números com parte decimal (com ou sem sinal);

Tabela 1.5: Padrões utilizados no FLEX

Padrão	Descrição
{macro}	Substituição/Expansão da macro definida anteriormente
(r)	O carácter “r”, sendo que os parêntesis permitem estipular precedências
xyz*	A sequência “xy” seguida de zero ou mais “z”s
(xyz)*	A sequência “xyz” repetida zero ou mais vezes
r s	O carácter “r” ou “s” (alternativa)
^r	O carácter “r” apenas se no início da linha
r\$	O carácter “r” apenas se no final da linha (não consome o \n)
^xyz\$	Uma linha que contém apenas a cadeia de caracteres “xyz”
<<EOF>>	Fim de ficheiro